

See discussions, stats, and author profiles for this publication at: <https://www.researchgate.net/publication/365798776>

Research on the Tourist Volume Forecast of Scenic Spots Considering the Effect of Holidays–A Hybrid Prediction Method Based on Prophet–NNAR

Article · June 2022

DOI: 10.12341/jssms21561

CITATIONS

0

READ

1

2 authors, including:



Yong Li

Capital University of Economics and Business, Be

3 PUBLICATIONS 1 CITATION

SEE PROFILE

Some of the authors of this publication are also working on these related projects:



Tourism big data [View project](#)



Tourism demand forecasting [View project](#)

考虑节假日影响效应的景区客流量预测研究——基于 Prophet-NNAR 的混合预测方法^{*}

李 勇 李云鹏

(首都经济贸易大学工商管理学院, 北京 100070)

摘要 近年来, 旅游景区因超负荷接待造成游客滞留的事件屡见不鲜, 如何准确有效地预测景区客流量、合理调配资源成为眼下景区管理者十分关切的问题. 由于节假日等外部因素的影响, 景区客流量的时间序列曲线通常呈现非线性的特征, 这增加了准确预测旅游客流量的难度. 文章提出一种考虑节假日影响效应的景区客流量预测方法, 即 Prophet-NNAR 混合预测方法: 首先, 基于考虑了节假日影响因素的 Prophet 模型预测原始景区客流量序列; 其次, 使用神经网络自回归模型 (NNAR) 对 Prophet 模型预测值的残差部分进行预测; 最后, 将二者相加作为 Prophet-NNAR 混合模型的最终预测结果. 文章以 2013 年 1 月 1 日至 2017 年 7 月 31 日的九寨沟景区历史客流量数据为研究样本, 使用 R 软件验证 Prophet-NNAR 混合预测方法的有效性, 研究发现 Prophet-NNAR 混合预测方法的预测性能除了优于单一的模型方法 (Prophet 模型、不考虑节假日效应 Prophet 模型、NNAR 模型) 外, 还强于季节自回归求和滑动平均 (SARIMA)、指数平滑模型 (ETS). 此外, 借助 Diebold-Mariano 检验进一步确定了 Prophet-NNAR 模型的优异性.

关键词 Prophet, NNAR, 混合预测, 客流量预测, 节假日效应.

MR(2000) 主题分类号 62P25, 62M10, 62M20

DOI 10.12341/jssms21561

Research on the Tourist Volume Forecast of Scenic Spots Considering the Effect of Holidays — A Hybrid Prediction Method Based on Prophet-NNAR

LI Yong LI Yunpeng

(School of Business Administration, Capital University of Economics and Business, Beijing 100070)

Abstract Recently, incidents of tourists being stranded due to the overloaded reception of tourists in attractions are very common. Therefore, accurate and effective

^{*} 北京市自然科学基金面上项目 (9222005) 资助课题.

收稿日期: 2021-10-03, 收到修改稿日期: 2022-03-15.

通信作者: 李云鹏, Email: liyunpeng@cueb.edu.cn.

编委: 余乐安.

prediction of the tourist volume in attractions and rational allocation of resources has become a challenge for scenic spot managers. Because of the influence of external factors, such as holidays, the time series curve of tourist volume in attractions usually presents nonlinear characteristics, which undoubtedly increases the practical difficulty of accurately predicting the tourist volume. This study proposes a method for forecasting tourist volume in attractions that considers the effects of holidays, namely, the Prophet-neural network autoregressive (NNAR) hybrid forecasting method. First, the Prophet model, which considers the effects of holidays, is used to predict the original tourist volume of attractions. Then, the NNAR model is used to predict the residual part of the predicted value of the Prophet model. Finally, the two results are combined as the final prediction result of the Prophet-NNAR hybrid model. Taking the historical tourist volume data of Jiuzhaigou scenic spot (from January 1, 2013 to July 31, 2017) as the data source, the effectiveness of the Prophet-NNAR hybrid forecasting method is verified using the R software. Results show that the Prophet-NNAR hybrid forecasting method is effective. The prediction performance of the Prophet-NNAR hybrid forecasting method is not only better than that of single-model methods (i.e., Prophet model, Prophet model that does not consider the effects of holidays, and NNAR model) but also stronger than the seasonal autoregressive integrated moving average and exponential smoothing models. Moreover, the combined results of the Diebold-Mariano test can confirm that the superiority of the Prophet-NNAR hybrid forecasting method over the other methods is statistically significant.

Keywords Prophet, NNAR, hybrid method, tourist volume forecast, holiday effect.

1 引言

客流预测作为旅游管理领域重要的研究方向之一, 及时准确的预测结果有利于管理者在景区运营和安全管理中做到“未雨绸缪”, 实现景区的科学化管控^[1, 2]. 就景区客流量预测而言, 数据源与预测方法长期以来都是客流量预测研究中需要被重点关注的两个部分^[2]. 不同数据源和预测方法的组合, 会对预测精度产生不同影响结果^[3].

从数据源上看, 景区历史客流量数据属于时间序列数据^[4], 数据序列中每个观测值的大小是影响客流量变化的各种因素在同一时刻的综合结果. 在旅游预测领域, 历史客流量的时间序列数据是最常见、最基本的数据源^[5, 6]. 先前学者的研究探讨了互联网搜索数据^[7-10]、天气数据^[2]、交通数据^[4]、评论数据^[11]等数据源与旅游客流量之间的关系, 发现在预测模型中加入除历史客流量数据之外的数据源能提高模型的预测准确度^[2]. 然而, 这些外部数据的获取往往会增加景区管理者的运营成本. 从预测方法上看, 预测旅游客流量的方法有很多, 如时间序列方法、计量经济学方法、机器学习方法、以及混合模型方法^[2, 12, 13]. 然而, 每种模型或方法都有自身的局限性^[5, 14], 并且旅游需求的预测也十分复杂, 因此尚且没有哪一种方法可以适用于所有的预测情况^[13]. 近年来, 将不同预测方法的混合预测成为旅游预测研究的热点之一^[15-17]. 例如, 张婷婷等人^[15]将一种人工智能优化算法(即烟花算法)应用于支持向量机参数选择的过程, 提出了基于季节调整的 FWA-SVR 模型, 并将其应用于旅游经济和旅游人数的预测研究.

旅游客流量会受到节假日、价格、天气等众多因素直接或间接影响^[7, 8, 18-21]. 不同节

假日的假期内具有各自的波动,使得假日客流量呈现出复杂的非线性特征和季节性趋势^[22].在某些节假日,景区的客流量数值会远大于非节假日的客流量数值,这些特殊的客流量数值点通常被称为离群点.由于这些节假日及特殊事件的周期性不固定,因此无法用平稳的周期来建立模型.在预测建模时,通常的做法是对这些离群点进行删除、替换等处理后再构建模型^[23],这种处理方式忽略了节假日及特殊事件等因素对客流量时间序列的影响.此外,一些传统的时间序列预测方法(如季节自回归整合移动平均模型 ARIMA)要求数据自身或者差分之后具有平稳性,而且难以准确捕捉数据的非线性关系.

相比之下,由 Facebook 在 2017 年提出的 Prophet 时间序列预测算法既能够考虑节假日及特殊事件对时间序列的影响^[24],又能够适用于包含缺失值或异常值的时间序列数据,而不需要事先进行缺失值的处理,相比于其他预测算法具有一定的优势.与 Prophet 模型相似,神经网络自回归模型 (NNAR) 也允许时间序列之间存在复杂的非线性关系^[23].尽管 Prophet 模型与 NNAR 模型已经被广泛应用于环境监测,城市热岛、疾病防控等研究领域^[25-29],然而在旅游领域的研究应用较为缺乏.

基于上述研究背景,本文将 Prophet 模型和神经网络自回归模型 (NNAR) 相结合,提出了一种基于 Prophet-NNAR 混合预测方法,并将其应用于景区客流量的预测研究.该方法能将节假日效应纳入到预测模型中,考虑历史或未来的节假日对景区客流量的影响,同时利用神经网络自回归模型进一步提高模型的预测精度.本文以中国著名景点九寨沟景区作为应用算例,以 2013 年 1 月 1 日至 2017 年 6 月 30 日期间的每日客流量数据为实验基础,并借助网格搜索技术对模型超参数进行调优,探索了基于 Prophet-NNAR 模型的景区客流量预测方法的可行性和有效性.与之前的研究相比,本文的主要贡献在于将 Prophet 模型引入到旅游客流量预测研究中,并设计了基于 Prophet-NNAR 的混合预测方法.该方法能根据管理者的经验在执行预测前事先考虑到节假日的影响,为景区管理者及相关从业人员提供了一种有效且可行的预测思路.

本文的其余部分安排如下:第 2 部分介绍了 Prophet-NNAR 混合模型的设计思路及模型原理;第 3 部分是实证分析,介绍了数据的收集、数据处理、以及 Prophet-NNAR 混合模型的预测结果,同时对本文所提出的模型与几个基准模型之间的预测准确性进行了比较分析;第 4 部分是文章的结论及未来的研究展望.

2 Prophet-NNAR 混合预测方法的原理与设计

2.1 Prophet 模型原理

Prophet 是 Facebook 开源的对时间序列进行建模分析的带有可解释参数的模型.该模型将时间序列预测问题转换成由趋势、季节周期性和节假日及特殊事件三种主要成分综合作用的曲线拟合问题. Prophet 模型使用了一个可分解的时间序列模型^[30],将时间序列分解为趋势、周期性和节假日等成分,然后分别用这些组成部分对时间序列进行拟合,然后通过加法模型进行累加,其基本模型可以表示如下

$$y(t) = g(t) + s(t) + h(t) + \varepsilon_t, \quad (2.1)$$

其中, $g(t)$ 为趋势项,即表示线性或非线性趋势的部分; $s(t)$ 为周期性或季节项,对应的变化周期可以为年、季度、月度、每日等; $h(t)$ 为节假日项,即时间序列中那些非固定周期的节

假日或重复发生的事件对预测变量的影响. ε_t 为噪声项或成为误差项, 表示随机的、无法预测的波动.

2.1.1 趋势函数项

在 Prophet 模型中, 有两个重要的趋势模型项: 基于 logistic 函数的饱和增长模型和基于分段线性函数的模型. 通常, Prophet 模型会默认使用线性模型进行趋势成分的预测.

1) 饱和增长模型

在预测增长时, 通常可能会遇到最大可达点或极限值, 比如总人口规模, 在自然环境下的增长受到承载力的限制达到饱和, 其增长类型对应的基本形式为

$$g(t) = \frac{C}{1 + \exp[-k(t - m)]}, \quad (2.2)$$

其中, C 为承载力, 即增长趋势的上限值; k 为增长率, 反映的是增长速度的快慢; m 为偏移量.

然而, 上述基本模型的公式 (2.2) 的承载力 C 、增长率 k 为固定的值, 事实上, 承载力与增长率不是恒定不变的, 因此将增长率的变化点和趋势上限变化纳入增长模型中 (推导过程见 Taylor 和 Letham^[24] 的文章), 最终可以得到如下的分段 logistic 增长模型

$$g(t) = \frac{C(t)}{1 + \exp\{-(k + \alpha(t)^T \delta)[t - (m + \alpha(t)^T \gamma)]\}}, \quad (2.3)$$

其中, $C(t)$ 为承载力, 是时间 t 的函数, 反映了增长趋势的上限值在不同时段可能不同; $\alpha(t)$ 是一个指示函数, 取值为 0 或者 1, 反映变点的情况; δ 为增长率的变化向量; $k + \alpha(t)^T \delta$ 表示在 t 时刻的增长速率; $m + \alpha(t)^T \gamma$ 表示在 t 时刻的偏移量. 在 Prophet 中变点的位置是需要设置的, 每一段的趋势也会随着变点的设置而改变. 目前有两种方法去设置变点, 一种是人工指定的方式, 另一种是通过算法来自动选择.

2) 分段线性模型

对于没有饱和增长的趋势而言, 在分段上增长速率恒定, 其对应的分段线性模型如下

$$g(t) = (k + \alpha(t)^T \delta)t + (m + \alpha(t)^T \gamma), \quad (2.4)$$

其中, δ 为增长率的变化向量; $k + \alpha(t)^T \delta$ 表示在 t 时刻的增长速率; $m + \alpha(t)^T \gamma$ 表示在 t 时刻的偏移量.

2.1.2 季节周期性项

Prophet 模型利用傅立叶级数拟合序列中的周期性或季节性分量, 相应的季节周期性项的表达式如下

$$s(t) = \sum_{n=1}^N \left[a_n \cos\left(\frac{2\pi nt}{P}\right) + b_n \sin\left(\frac{2\pi nt}{P}\right) \right], \quad (2.5)$$

其中, P 为时间序列具有的周期, 当 $P = 7$ 时, 表示是以周为周期, $P = 365.25$ 时, 表示是以年为周期. a_n 和 b_n 是拟合时需要进行估计的参数. 虽然增大 N 可允许模型拟合变化更快的周期季节性, 但是也会增加过度拟合的风险. 在 Prophet 模型中, 默认使用 $N = 10$ 刻画以年为单位的周期性变化, $N = 3$ 刻画以周为单位的周期性变化.

2.1.3 节假日及特殊事件项

多数时间序列往往都会受到节假日或特殊事件的影响. 由于这些节假日或者特殊事件的周期性不固定, 因而无法用平稳的周期来建模. 在 Prophet 模型中, 单独考虑了节假日或特殊事件对时间序列的影响, 假设待分析的时间序列在过去时间和未来预测时间内一共有 L 个节假日或特殊事件, 并且假设节假日的影响是独立的, 那么节假日或特殊事件的基本模型可表示为

$$h(t) = Z(t)\mathbf{k} = \sum_{i=1}^L k_i \cdot \mathbf{1}(t \in D_i), \quad (2.6)$$

$$Z(t) = [\mathbf{1}(t \in D_1), \dots, \mathbf{1}(t \in D_i), \mathbf{1}(t \in D_L)], \quad (2.7)$$

其中, $\mathbf{k} \sim \text{Normal}(0, v^2)$, k_i 为节假日或特殊事件对应的参数, 表示节假日或特殊事件对预测的影响; D_i 表示节假日或特殊事件对应的过去和未来的日期集合. $Z(t)$ 为节假日或特殊事件所对应的虚拟变量生成的矩阵.

2.2 NNAR 模型原理

神经网络的基本结构包括输入层、隐藏层和输出层. 与线性自回归模型中使用滞后值作为自变量一样, 神经网络自回归 (NNAR) 模型是一个可滞后输入的前馈神经网络^[23]. 对于单变量的时间序列数据, 使用其滞后值作为神经网络的输入, 采用一个带有节点的隐藏层来进行拟合, 其输出 y_t 和输入 $(y_{t-1}, y_{t-2}, \dots, y_{t-p})$ 之间的关系可表示如下^[31]

$$y_t = w_0 + \sum_{j=1}^h w_j \cdot g \left(w_{0,j} + \sum_{i=1}^n w_{i,j} \cdot y_{t-i} \right) + \varepsilon_t, \quad (2.8)$$

其中, h 为隐藏层的节点数, n 为输入层的节点数, $w_{i,j}$ ($i = 0, 1, \dots, n; j = 1, 2, \dots, h$) 和 w_j ($j = 0, 1, \dots, h$) 是模型的参数或者连接权重. ε_t 为残差序列.

参考 Maleki 等人^[31]的研究, 本文仅考虑具有一个隐藏层的前馈网络情况, 可用符号 NNAR(p, k) 表示隐藏层中有 p 期滞后输入、且神经网络中隐藏层有 k 个神经元, 对应的输入层为 $(y_{t-1}, y_{t-2}, \dots, y_{t-p})$. 更一般地, 如果时间序列是季节性数据 (季节周期 m), 可以在输入层中增加同一季节的最后观测值, 用符号 NNAR(p, q, k) _{m} 表示隐藏层有 k 个神经元的神经网络, 季节滞后周期为 q 的神经网络, 对应的输入层为 $(y_{t-1}, y_{t-2}, \dots, y_{t-p}, y_{t-m}, y_{t-2m}, \dots, y_{t-qm})$.

2.3 基于 Prophet-NNAR 混合预测方法

基于 Prophet-NNAR 模型的混合预测方法的设计思路 (如图 1 所示) 为: 首先, 将景区的每日客流量的时间序列数据分为训练集、验证集和测试集. 其次, 利用训练集构建 Prophet 模型, 以验证集上 Prophet 模型预测精度的均方根误差 (RMSE) 最小为标准确定其超参数的最优取值; 再次, 使用 NNAR 模型去拟合 Prophet 模型在训练集上的残差, 并以验证集上 NNAR 模型的误差最小为标准确定未知参数取值; 最后, 在确定了最优超参数取值的情况下, 分别构建基于原始序列数据的 Prophet 模型和基于残差序列的 NNAR 模型, 同时将 Prophet 模型和 NNAR 的预测值求和的结果作为 Prophet-NNAR 混合模型的最终预测值. 相应的步骤如下

1) 首先, 构建旅游目的地的节假日列表, 对 Prophet 模型的基本参数进行设定, 在训练集上对景区历史客流量时间序列 H_t 构建预测模型, 结合超参数优化选择模型超参数的最优

取值, 进行预测并得到预测值序列 \hat{L}_t , 则可得 Prophet 模型与景区历史客流量的时间序列的残差为: $\alpha_t = H_t - \hat{L}_t$;

2) 其次, 用 NNAR 模型对残差序列 α_t 构建预测模型, 确定最优模型后, 进一步得到预测结果 $\hat{\alpha}_t$;

3) 最后, 将前两步中的预测结果求和, 即 $\hat{H}_t = \hat{L}_t + \hat{\alpha}_t$, 并将求和后的值作为 Prophet-NNAR 的混合预测的最终结果.




图 1 混合预测方法的模型设计示意图

(Figure 1 A diagram of the model design of the hybrid prediction method)

3 实证分析

3.1 数据收集及预处理

本文以国家重点风景名胜区——九寨沟为算例, 探究 Prophet-NNAR 的混合预测方法应用于旅游游客量预测的可行性与有效性. 在实验中, 本文选取九寨沟景区 2013 年 1 月 1 日至 2017 年 7 月 31 日一共 1673 天的历史游客人数数据, 这些数据来源于九寨沟景区官网 (www.jiuzhai.com). 为了方便区分每一年节假日期间与非节假日对应的客流量数据点, 本文分别用实心正方形点表示节假日期间的客流量点, 空心倒三角形点表示非节假日期间的客流量点, 绘制了九寨沟景区历史客流量的变化曲线, 如图 2 所示. 由图 2 可知, 九寨沟景区的客流量曲线呈现出较强的周期性和季节性特征, “离群点” 大多出现在节假日期间, 这说明节假日期间旅游景区会面临游客“扎堆式”旅游的现象, 景区客流量数据受节假日的影响较大. 此外, 还可以发现在每年 7 月至 8 月期间是九寨沟景区的客流高峰期, 每日接待的客流量较大.




图 2 九寨沟景区客流量曲线

(Figure 2 Tourist volume curve of Jiuzhaigou Scenic Area)

本文参考 Bi 等人^[2]对数据集的划分方式,将九寨沟景区 2013 年 1 月 1 日至 2017 年 5 月 31 日的客流量数据作为训练集,2017 年 6 月 1 日至 2017 年 6 月 30 日期间的客流量数据作为验证集,2017 年 7 月 1 日至 2017 年 7 月 31 日的客流量数据作为测试集.此外,由于九寨沟历史客流量之间的数值差异较大,为了提高模型得预测精确度,在数据集划分之前本文先将历史客流量数值均除以 1000,处理后的客流量数据单位为千人.

3.2 构建 Prophet-NNAR 混合预测模型的过程

3.2.1 基于原始客流量数据的 Prophet 预测

节假日或特殊事件会对旅游景区的客流量造成很大的影响,这种影响尽管在各年中表现相似,但是这些时间点对应的数据往往不存在周期性的特征.因此,在使用 Prophet 模型对景区客流的时间序列数据进行训练和预测时,可以结合实际情况对节假日的预先设定,这样有利于更好地预测景区客流量.

根据国务院办公厅发布的历年假期安排通知,本文构建了相应的节假日列表,如表 1 所示.通过设定节假日放假起始日期、节前扩展天数和节后扩展天数,就可以让 Prophet 模型识别出每一类假期对客流量产生影响的时间范围,有利于 Prophet 模型对数据中存在节假日的突变点(即数据中突增或突减的点)的拟合.根据九寨沟景区管理者的建议,实验中节前拓展和节后扩展分别在假期起始日、假期结束日的基础上多加 1 天.

表 1 2013-2017 年中国重要节假日列表
(Table 1 List of important holidays in China from 2013 to 2017)

假期类型	2013-2017 年假期起始日	节前 节后		
		假期 n 天	扩展 n 天	扩展 n 天
元旦	2013-01-01, 2014-01-01 ^a , 2015-01-01, 2016-01-01, 2017-01-01	1/3	1	4
春节	2013-02-09, 2014-01-31, 2015-02-18, 2016-02-07, 2017-01-27	7	1	8
清明节	2013-04-04, 2014-04-05, 2015-04-05, 2016-04-04, 2017-04-02	3	1	4
劳动节	2013-04-29, 2014-05-01, 2015-05-01, 2016-05-01, 2017-05-01	3	1	4
端午节	2013-06-10, 2014-06-02, 2015-06-20, 2016-06-09, 2017-05-28	3	1	4
中秋节	2013-09-19, 2014-09-08, 2015-09-27, 2016-09-15	3	1	4
国庆节	2013-10-01, 2014-10-01, 2015-10-01, 2016-10-01	7	1	8

注: a. 2014 年 1 月元旦放假 1 天.

在构建了节假日列表后,本文对 Prophet 模型的参数进行选择 and 设置. Prophet 模型的参数可以分为两类,分别是基本参数和可调超参数.表 2 对基本参数的含义及参数取值进行说明.

表 2 Prophet 模型基本参数设置
(Table 2 Basic parameter settings of Prophet model)

参数名	说明	取值设置
growth	设置增长趋势的类型, 可以设置 “linear” 或 “logistic” 指定线性或 logistic 趋势	linear
changepoints	可以设置拐点的具体日期位置, 默认值为 “None”	None
n.changepoints	设置拐点个数, 默认值为 25. 如果提供了输入 “changepoints”, 则不使用.	25
changepoint.range	估计趋势变化点的历史比例, 默认值为 0.8 表示在数据的前 80% 处寻找潜在变化点	0.95
holidays	设置节假日的数据框, 可以指定要作为假日包含的日期, 及假期扩展前后的天数范围	见表 1
seasonality.mode	季节性模式, 可选 “additive” (加法模式) 或者 “multiplicative” (乘法模式), 默认为加法模式	multiplicative

注: 未列出的其他基本参数, Prophet 模型建模时均按默认值处理.

为了使得 Prophet 模型在验证数据集上表现性能最佳, 实验中通常需要进行超参数的选择. 在 Prophet 模型参数中有 3 个较为重要的超参数, 它们分别为 changepoint.prior.scale、seasonality.prior.scale、holidays.prior.scale, 其参数含义、合理范围和参数取值如表 3 所示. 参考 Hyndman 和 Athanasopoulos^[23] 的文章中对参数的划分可知, 这三个超参数组合 (changepoint.prior.scale, seasonality.prior.scale, holidays.prior.scale) 一共有 64 种组合方式. 为了确定超参数的最优组合, 本文采用了网格搜索技术^[2], 即在参数调整的合理范围内依次挑选一种组合方式作为模型的超参数取值, 以此来训练模型, 并以验证集上的预测模型的均方根误差 (RMSE) 最小为标准寻找最优参数组合, 最终得到了上述三个超参数最优组合 (0.5, 0.01, 0.1).

表 3 Prophet 模型超参数调整
(Table 3 Hyperparameter adjustment of Prophet model)

超参数	含义	合理范围	参数取值
changepoint.prior.scale	趋势灵活性的调节参数, 其默认值为 0.05	[0.001, 0.5]	{0.001, 0.01, 0.1, 0.5 }
seasonality.prior.scale	控制季节灵活性的参数, 其默认值为 10	[0.01, 10]	{ 0.01 , 0.1, 1, 10}
holidays.prior.scale	控制节日效果的灵活性的参数, 其默认值为 10	[0.01, 10]	{0.01, 0.1 , 1, 10}

注: 参数取值中加粗的数值为实验中通过网格搜索技术确定的最优取值.

在超参数的最优组合下, Prophet 模型在训练集和验证集上的预测结果及残差序列如图 3 所示. Prophet 模型对客流量时间序列的拟合情况较好, 且较好地捕捉到了节假日日期对应的客流量数值点. 此外, 残差序列并未呈现出明显的趋势及季节性特征.

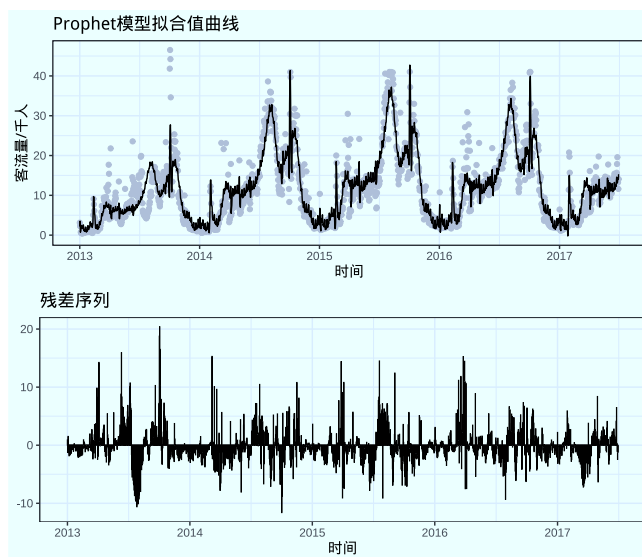


图3 Prophet 预测模型拟合值曲线及残差序列

(Figure 3 Prophet prediction model fitted value curve and residual sequence)

3.2.2 基于残差序列的 NNAR 预测

在时间序列分析中,通过对序列进行单位根检验和 Ljung-Box 检验,可以检验时间序列是否存在平稳性和自相关性.将残差序列分别进行单位根检验和 Ljung-Box 检验,其中单位根检验的结果中 $p\text{-value}=0.01$,说明残差序列是平稳的时间序列,没有趋势及季节性成分,而 Ljung-Box 检验的结果中 $p\text{-value}<2.2e-16$,说明残差序列存在滞后相关性,因此只需要考虑 $\text{NNAR}(p,k)$ 对残差序列进行建模.在模型参数的选择上,本文参考了 Yu 等人^[32]的做法,即除了使用 R 软件中对应函数对模型参数进行自动选择外,还额外考虑了输入滞后期 p 取 $1\sim 10$ 对应的 NNAR 模型,即 $\text{NNAR}(1,k), \text{NNAR}(2,k), \dots, \text{NNAR}(10,k)$.实验中,NNAR 模型参数自动选择的结果为 $\text{NNAR}(8,4)$.通过比较这 11 个备选的 NNAR 模型的预测精度,以在验证集上的均方根误差 (RMSE) 最小为选择标准,最终发现模型 $\text{NNAR}(5,3)$ 对残差序列的拟合效果最好.

3.2.3 生成 Prophet-NNAR 的混合预测结果

在确定好模型参数及超参数的取值后,分别使用 Prophet 模型和 $\text{NNAR}(5,3)$ 模型对未来的某个时间段进行预测,将这两个模型的预测结果相加,即可得到 Prophet-NNAR(5,3) 混合预测模型的预测值.

3.3 基准模型及参数设置

为了验证 Prophet-NNAR 的混合预测模型的有效性,本文分别将季节自回归整合移动平均模型 (SARIMA)、神经网络自回归模型 (NNAR)、Prophet 模型、不考虑节假日的 Prophet 模型 (下文用 $N\text{-Prophet}$ 表示)、指数平滑模型 (ETS) 作为基准模型.实验中这几个基准模型的参数设置如表 4 所示.

表 4 基准模型参数设置
(Table 4 Benchmark model parameters settings)

基准模型	参数设置
SARIMA	自相关阶数 $p = 5$, 差分阶数 $d = 1$, 滑动平均阶数 $q = 3$, 季节性自相关 $P = 0$, 季节性差分阶数 $D = 1$, 季节性滑动平均 $Q = 1$, 单个季节性时段的时间步 $m = 7$
NNAR	输入滞后期 $p = 16$, 隐藏层神经元节点数 $k = 8$
Prophet	参数取值与表 1、表 2 和表 3 一致
N-Prophet	未考虑节假日参数的设置 (holidays), 其他参数与表 2 和表 3 一致
ETS	带乘性误差的 Holt 线性模型 ETS(M, A, N), $\alpha = 0.9999$, $\beta = 0.0002$, $l = 2.0668$, $b = 0.3216$, $\varepsilon = 0.3297$

3.4 评价指标

在不同模型预测精度的比较上, 本文采用了均方根误差 (RMSE)、平均绝对百分比误差 (MAPE)、平均绝对误差 (MAE) 这三个指标来比较 Prophet-NNAR 的混合预测方法与上述几个基准模型的预测效果. 各个指标对应的计算公式分别如下

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{n=1}^N (y_n - \hat{y}_n)^2}, \tag{3.1}$$

$$\text{MAPE} = \frac{100\%}{N} \sum_{n=1}^N \left| \frac{y_n - \hat{y}_n}{y_n} \right|, \tag{3.2}$$

$$\text{MAE} = \frac{1}{N} \sum_{n=1}^N |y_n - \hat{y}_n|, \tag{3.3}$$

其中, y_n 为景区历史游客人数的真实值, \hat{y}_n 为模型的预测值, N 为预测记录数. RMSE、MAPE、MAE 的取值越小, 说明对应的模型预测性能越好.

3.5 结果分析

图 4 绘制了不同方法模型在测试集 (日期为 2017 年 7 月 1 日至 2017 年 7 月 31 日) 上的预测值与景区客流量真实值折线图. 在 31 天的预测值里, Prophet-NNAR(5, 3) 模型的预测值最接近真实值 (即预测值和真实值误差的绝对值最小) 的情况有 10 天, 其次则是 Prophet 模型有 6 天. 相比之下, NNAR 模型的预测结果中只有 2 天最接近真实值. 这表明混合模型的预测效果要优于单个模型. 此外, 不考虑节假日效应的 N-Prophet 模型的预测效果比考虑了节假日效应的 Prophet 模型和 Prophet-NNAR 混合模型的预测效果更差. 总体上看, Prophet-NNAR 混合预测模型和 Prophet 模型的预测效果比 NNAR 模型、ETS 模型、SARIMA 模型更好.




图 4 不同预测模型方法的结果比较

(Figure 4 Comparison of results of different forecasting model methods)

为了更准确地评价不同预测模型的性能, 分别计算了各个模型的均方根误差 (RMSE)、平均绝对百分比误差 (MAPE)、平均绝对误差 (MAE), 结果如表 5 所示.

表 5 不同模型预测精度比较

(Table 5 Comparison of prediction accuracy of different models)

模型	RMSE	MAPE	MAE
SARIMA(5, 1, 3) × (0, 1, 1) ₇	5.8183	26.75%	33.8521
N-Prophet	2.3854	9.59%	1.9203
NNAR(16, 8)	3.6156	13.39%	2.6347
ETS(M, A, N)	3.6967	14.32%	2.7808
Prophet	1.7577	7.39%	1.4567
Prophet-NNAR(5, 3)	1.6178	6.54%	1.3045

由表 5 可知, 本文所提出的 Prophet-NNAR 混合预测模型无论是在 RMSE、MAPE、还是 MAE 方面的预测误差都要比单一模型 (如 Prophet 模型、NNAR 模型、以及其他基准模型) 更小. 这说明相比其他基准模型, Prophet-NNAR 混合预测模型的预测精度最高, 进一步证实了 Prophet-NNAR 的混合预测模型的有效性. 而在所有基准模型中 SARIMA 模型预测效果相对最差, 原因可能是因为这种传统的时间序列方法比较依赖过去的历史数据和变化规律 [5, 33], 外界因素 (比如节假日、地震等) 对景区客流量数据的影响效应难以被 SARIMA 模型捕捉. 此外, 通过比较 Prophet 模型和 N-Prophet 模型的预测精度可知, 考虑了节假日效应的 Prophet 模型的预测效果要优于不考虑节假日效应的 N-Prophet 模型, 这说明在构建 Prophet 模型时对节假日效应的设定有利于 Prophet 模型对景区客流量时间序列中节假日“离群点”的拟合, 同时也体现了 Prophet 模型在旅游客流量预测中的优势.

为了验证所提出的 Prophet-NNAR 模型的预测性能是否显著优于基准模型, 本文进一步采用 Diebold-Mariano (DM) 检验进行验证, 结果见表 6 所示. DM 检验的原假设是“两种

模型的预测精度相同”。由表 6 可知,除了 Prophet-NNAR 模型在 90% 的置信水平上显著优于 Prophet 模型外,Prophet-NNAR 模型均在 95% 的置信度水平上显著优于其他几个基准模型.因此,本文所提出的 Prophet-NNAR 模型的预测性能要显著优于基准模型.

表 6 Diebold-Mariano 的检验结果
(Table 6 The results of Diebold-Mariano test)

基准模型	DM-stat.	p 值
SARIMA(5, 1, 3) × (0, 1, 1) ₇	−3.8939	0.0005
NNAR(16, 8)	−2.5363	0.0166
ETS(M, A, N)	−2.9584	0.0060
N-Prophet	−2.0982	0.0444
Prophet	−1.7710	0.0867

4 结 论

景区客流量的时间序列数据往往都会受到节假日、地震、以及特殊事件的影响,但是这些节假日或者特殊事件的周期性不固定,因而无法用平稳的周期来建模.本文提出了一种基于 Prophet-NNAR 混合模型的景区客流量预测方法,该方法能考虑历史或者未来的节假日因素对景区客流量的影响,同时利用神经网络进一步提高模型的预测精度.本文选择以中国著名景点九寨沟景区作为应用算例,研究结果表明 Prophet-NNAR 混合预测方法,结果表明 Prophet-NNAR 混合预测方法的预测性优于 Prophet 模型、不考虑节假日效应 Prophet 模型、NNAR 模型、SARIMA 模型、以及 ETS 模型.

对景区管理者来说,历史客流量数据相对于其他数据源而言更容易获得.本文所提出的混合预测方法仅基于景区的历史客流量数据,能结合景区自身客流量的实际特征规律对节假日参数进行设置,模型算法易于执行和实现,对客流量的预测效果也相对较好.因此,本文所提出的考虑节假日效应的 Prophet-NNAR 混合预测方法具有一定的价值性和应用性,能为九寨沟及相关景区的管理者、旅游及相关行业人员提供了一种新的预测方法.

此外,本文所提出的 Prophet-NNAR 混合预测方法还可以进一步展开深入研究.例如,该预测方法可以用于同样受到周末及假日影响的零售业及其他行业的业务预测.鉴于 Prophet 模型对预测变量具有良好的扩展性,未来的预测研究可以将外部数据如天气数据、搜索数据等,亦或者考虑 Prophet 模型与其他方法的混合使用.

参 考 文 献

[1] Song H. Tourism forecasting: An introduction. *International Journal of Forecasting*, 2011, **27**(3): 817–821.

[2] Bi J W, Liu Y, Li H. Daily tourism volume forecasting for tourist attractions. *Annals of Tourism Research*, 2020, **83**: 102923.

- [3] Sun S, Wei Y, Tsui K L, et al. Forecasting tourist arrivals with machine learning and internet search index. *Tourism Management*, 2019, **70**: 1–10.
- [4] Lu H, Zhang J, Xu Z, et al. Prediction of tourist flow based on multi-source traffic data in scenic spot. *Transactions in GIS*, 2021, **25**(2): 1082–1103.
- [5] García Rodríguez Ó. Forecasting tourism arrivals with an online search engine data: A study of the Balearic Islands. *Pasos Revista De Turismo Y Patrimonio Cultural*, 2017, **15**(4): 943–958.
- [6] Lin S J, Chen J Y, Liao Z X. An EMD-BP integrated model to forecast tourist number and applied to Jiuzhaigou. *Journal of Intelligent & Fuzzy Systems*, 2018, **34**(2): 1045–1052.
- [7] Ongan S, Gozgor G. Tourism demand analysis: The impact of the economic policy uncertainty on the arrival of Japanese tourists to the USA. *International Journal of Tourism Research*, 2018, **20**(3): 308–316.
- [8] Liu Y Y, Tseng F M, Tseng Y H. Big Data analytics for forecasting tourism destination arrivals with the applied vector autoregression model. *Technological Forecasting and Social Change*, 2018, **130**: 123–134.
- [9] Zhang B, Li N, Shi F, et al. A deep learning approach for daily tourist flow forecasting with consumer search data. *Asia Pacific Journal of Tourism Research*, 2020, **25**(3): 323–339.
- [10] Clark M, Wilkins E J, Dagan D T, et al. Bringing forecasting into the future: Using Google to predict visitation in U.S. national parks. *Journal of Environmental Management*, 2019, **243**: 88–94.
- [11] Fronzetti Colladon A, Guardabascio B, Innarella R. Using social network and semantic analysis to analyze online travel forums and forecast tourism demand. *Decision Support Systems*, 2019, **123**: 113075.
- [12] Song H, Li G. Tourism demand modelling and forecasting — A review of recent research. *Tourism Management*, 2008, **29**(2): 203–220.
- [13] Song H, Qiu R T R, Park J. A review of research on tourism demand forecasting: Launching the Annals of Tourism Research Curated Collection on tourism demand forecasting. *Annals of Tourism Research*, 2019, **75**: 338–362.
- [14] Yang X, Pan B, Evans J A, et al. Forecasting Chinese tourist volume with search engine data. *Tourism Management*, 2015, **46**: 386–397.
- [15] 张婷婷, 王沫然, 魏得胜, 等. 季节调整 FWA-SVR 模型及其在旅游经济预测中的应用. *系统科学与数学*, 2021, **41**(6): 1572–1584.
(Zhang T T, Wang M R, Wei D S, et al. Seasonally-Adjusted FWA-SVR model and its application in tourism economic forecast. *Journal of Systems Science and Mathematical Sciences*, 2021, **41**(6): 1572–1584.)
- [16] 陆文星, 戴一茹, 李楚, 等. 基于改进 PSO-BP 神经网络的旅游客流量预测方法. *系统科学与数学*, 2020, **40**(8): 1407–1419.
(Lu W X, Dai Y R, Li C, et al. Tourist traffic flow forecasting method based on improved PSO-BP neural network. *Journal of Systems Science and Mathematical Sciences*, 2020, **40**(8): 1407–1419.)
- [17] Jiao E X, Chen J L. Tourism forecasting: A review of methodological developments over the last decade. *Tourism Economics*, 2019, **25**(3): 469–492.
- [18] Wei X, Huang S (SAM), Yap G, et al. The influence of national holiday structure on domestic tourism expenditure: Evidence from China. *Tourism Economics*, 2018, **24**(7): 781–800.
- [19] Liu H, Liu W, Wang Y. A study on the influencing factors of tourism demand from mainland China to Hong Kong. *Journal of Hospitality and Tourism Research*, 2021, **45**(1): 171–191.
- [20] Otero-Giráldez M S, Álvarez-Díaz M, González-Gómez M. Estimating the long-run effects of socioeconomic and meteorological factors on the domestic tourism demand for Galicia (Spain). *Tourism Management*, 2012, **33**(6): 1301–1308.
- [21] Song H, Li G, Witt S F, et al. Tourism demand modelling and forecasting: How should demand be measured?. *Tourism Economics*, 2010, **16**(1): 63–81.

- [22] Chen R, Liang C Y, Hong W C, et al. Forecasting holiday daily tourist flow based on seasonal support vector regression with adaptive genetic algorithm. *Applied Soft Computing*, 2015, **26**: 435–443.
- [23] Hyndman R J, Athanasopoulos G. Forecasting: Principles and Practice. OTexts, 2018.
- [24] Taylor S J, Letham B. Forecasting at scale. *The American Statistician*, 2018, **72**(1): 37–45.
- [25] Zhao N, Liu Y, Vanos J K, et al. Day-of-week and seasonal patterns of PM_{2.5} concentrations over the United States: Time-series analyses using the Prophet procedure. *Atmospheric Environment*, 2018, **192**: 116–127.
- [26] Samal K K R, Babu K S, Das S K, et al. Time series based air pollution forecasting using SARIMA and prophet model. Proceedings of the 2019 International Conference on Information Technology and Computer Communications, 2019, 80–85.
- [27] Li L, Zha Y, Zhang J, et al. Using Prophet forecasting model to characterize the temporal variations of historical and future surface urban heat island in China. *Journal of Geophysical Research: Atmospheres*, 2020, **125**(23): e2019JD031968..
- [28] Xie C, Wen H, Yang W, et al. Trend analysis and forecast of daily reported incidence of hand, foot and mouth disease in Hubei, China by Prophet model. *Scientific Reports*, 2021, **11**(1): 1445.
- [29] Silva E S, Hassani H, Heravi S, et al. Forecasting tourism demand with denoised neural networks. *Annals of Tourism Research*, 2019, **74**: 134–154.
- [30] Harvey A C, Peters S. Estimation procedures for structural time series models. *Journal of Forecasting*, 1990, **9**(2): 89–108.
- [31] Maleki A, Nasser S, Aminabad M S, et al. Comparison of ARIMA and NNAR models for forecasting water treatment plant's influent characteristics. *KSCE Journal of Civil Engineering*, 2018, **22**(9): 3233–3245.
- [32] Yu G, Feng H, Feng S, et al. Forecasting hand-foot-and-mouth disease cases using wavelet-based SARIMA-NNAR hybrid model. *Plos One*, 2021, **16**(2): e0246673.
- [33] Liang Y H. Forecasting models for Taiwanese tourism demand after allowance for Mainland China tourists visiting Taiwan. *Computers & Industrial Engineering*, 2014, **74**: 111–119.